Same Address, Different Truth: How Labeling Paradigms Shape Ground Truth in Ethereum Anomaly Detection Datasets

2026. 09. 14.

최재현, 이준승, 탁지원

프라이버시향상기술(PET) 연구실



Contents

1 Introduction

2 Dataset Overview

3 Methodology

4 Results

5 Limitations

6 Future Work

Introduction

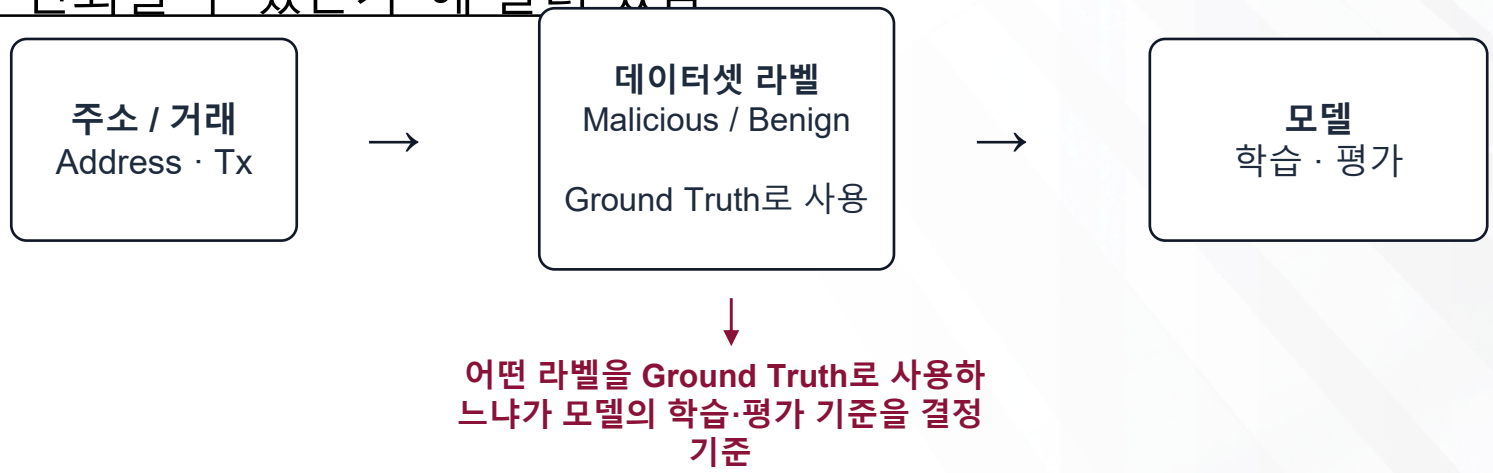
01

Introduction

PET

문제 배경

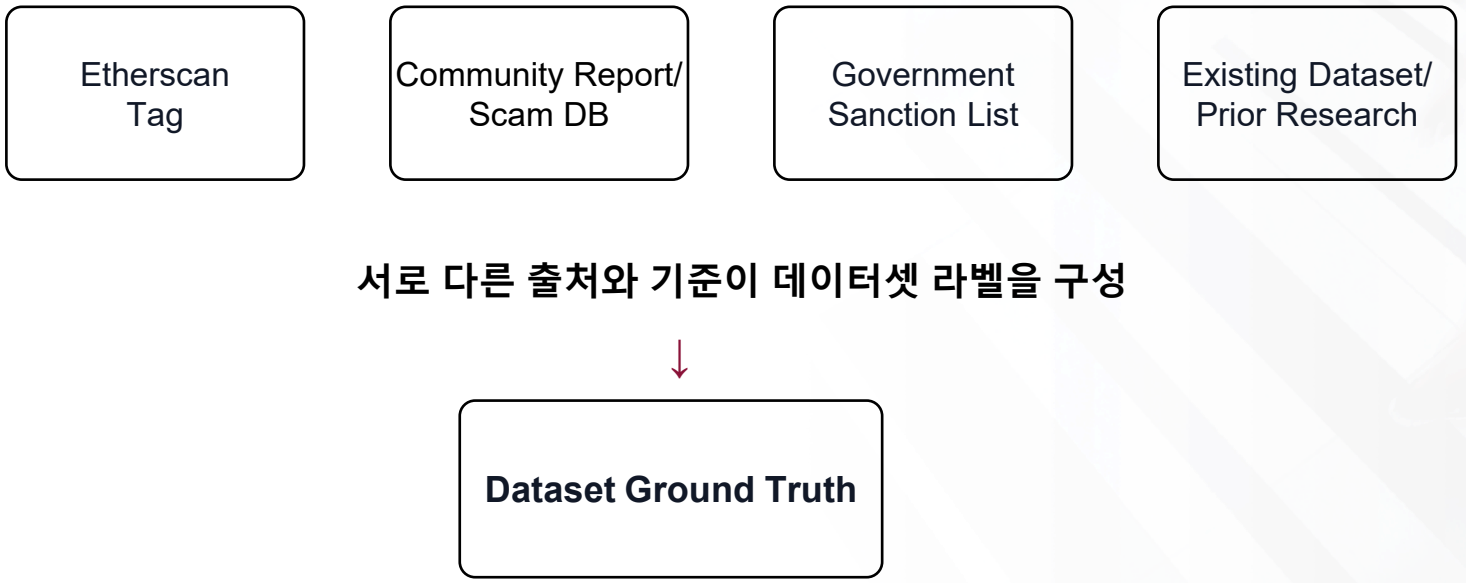
- Ethereum 네트워크에서 Phishing, Scam, Hack/Exploit 등으로 인한 피해 규모가 지속적으로 확대되고 있음
- 이에 대응하여 다수의 연구가 그래프 임베딩, 이상탐지 알고리즘 등을 활용한 Ethereum anomaly detection 모델을 제안해 옴
  - 이러한 모델들은 모두 공개된 라벨링 데이터셋을 학습·평가의 ground truth로 사용함
- 즉 탐지 성능의 신뢰성은 궁극적으로 “ground truth 데이터셋 자체가 얼마나 신뢰할 수 있는가”에 달려 있음



Introduction

문제 제기

- 하지만 블록체인 데이터셋의 라벨은 하나의 공통된 기준으로 만들어지지 않음
- 데이터셋마다 사용하는 정보 출처와 악성 행위의 정의가 다르며,
  일부 데이터셋은 기존 라벨을 재사용하거나 heuristic을 통해 악성 주소를 확장하기도 함

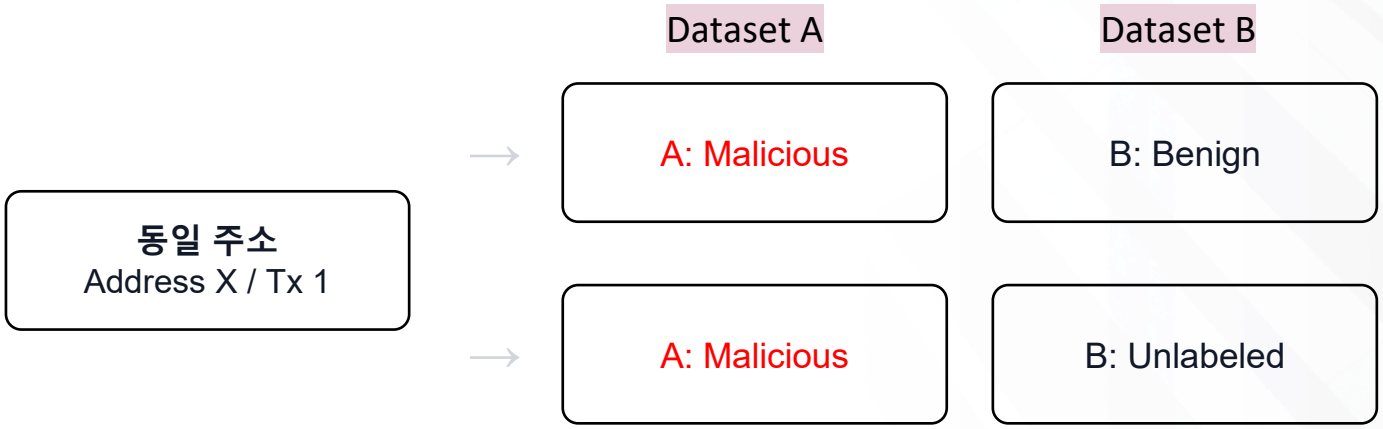


Introduction

PET

문제 제기

- 라벨의 정의와 구성 방법이 다르다면, 동일한 블록체인 주소 또는 거래도 데이터셋에 따라 서로 다른 상태로 나타날 수 있음
  - 만약 데이터셋 간 라벨이 체계적으로 불일치한다면, 이를 인지하지 못한 채 보고되는 정확도·F1 등의 지표는 실제 탐지 성능을 반영하지 못할 수 있음



Introduction

PET

연구 목적

- **RQ1. 동일한 Ethereum 주소에 대해, 서로 다른 공개 데이터셋들은 얼마나 일치하는 라벨을 부여하는가?**
  - 각 데이터셋의 anomaly / malicious 기준 정리
  - 공통 주소의 Malicious · Benign · Unlabeled · Absent 비교

- **RQ2. 라벨이 불일치하는 경우, 그 불일치는 무엇으로 설명되는가 — 데이터 수집 시점의 차이인가, 원 출처의 차이인가, 혹은 다른 구조적 요인인가?**
  - Etherscan, 정부기관, 논문, heuristic 등 출처 확인 등

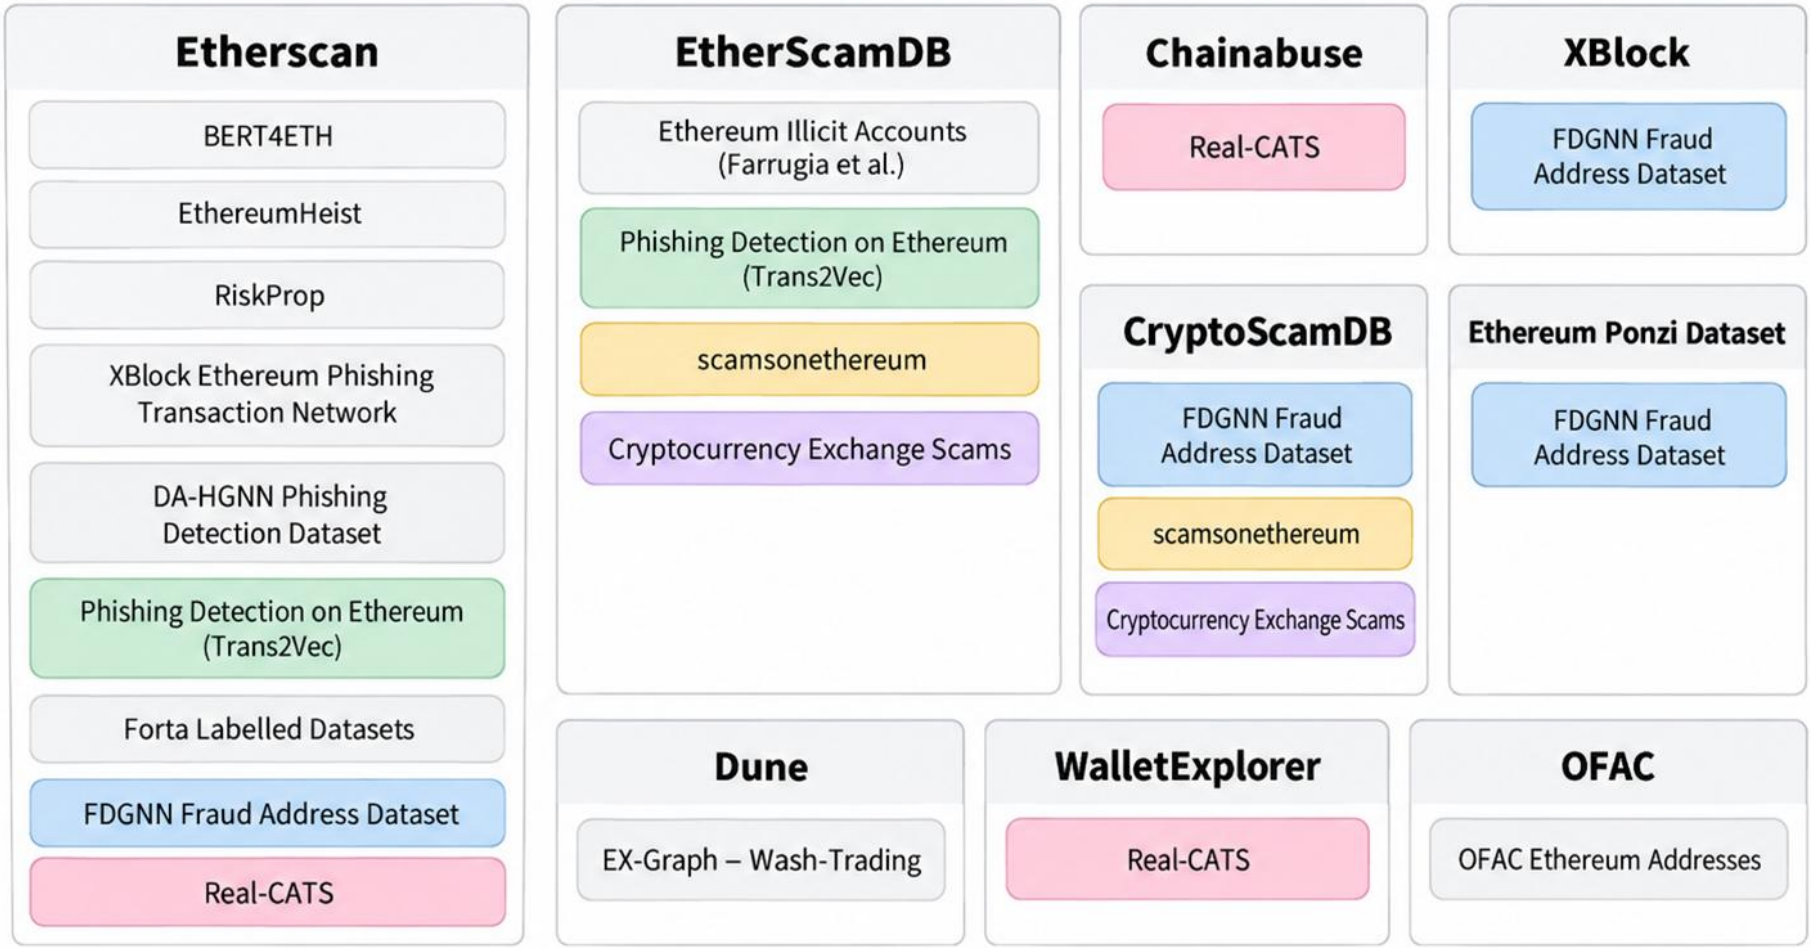
Dataset Overview

02

Dataset Overview

PET

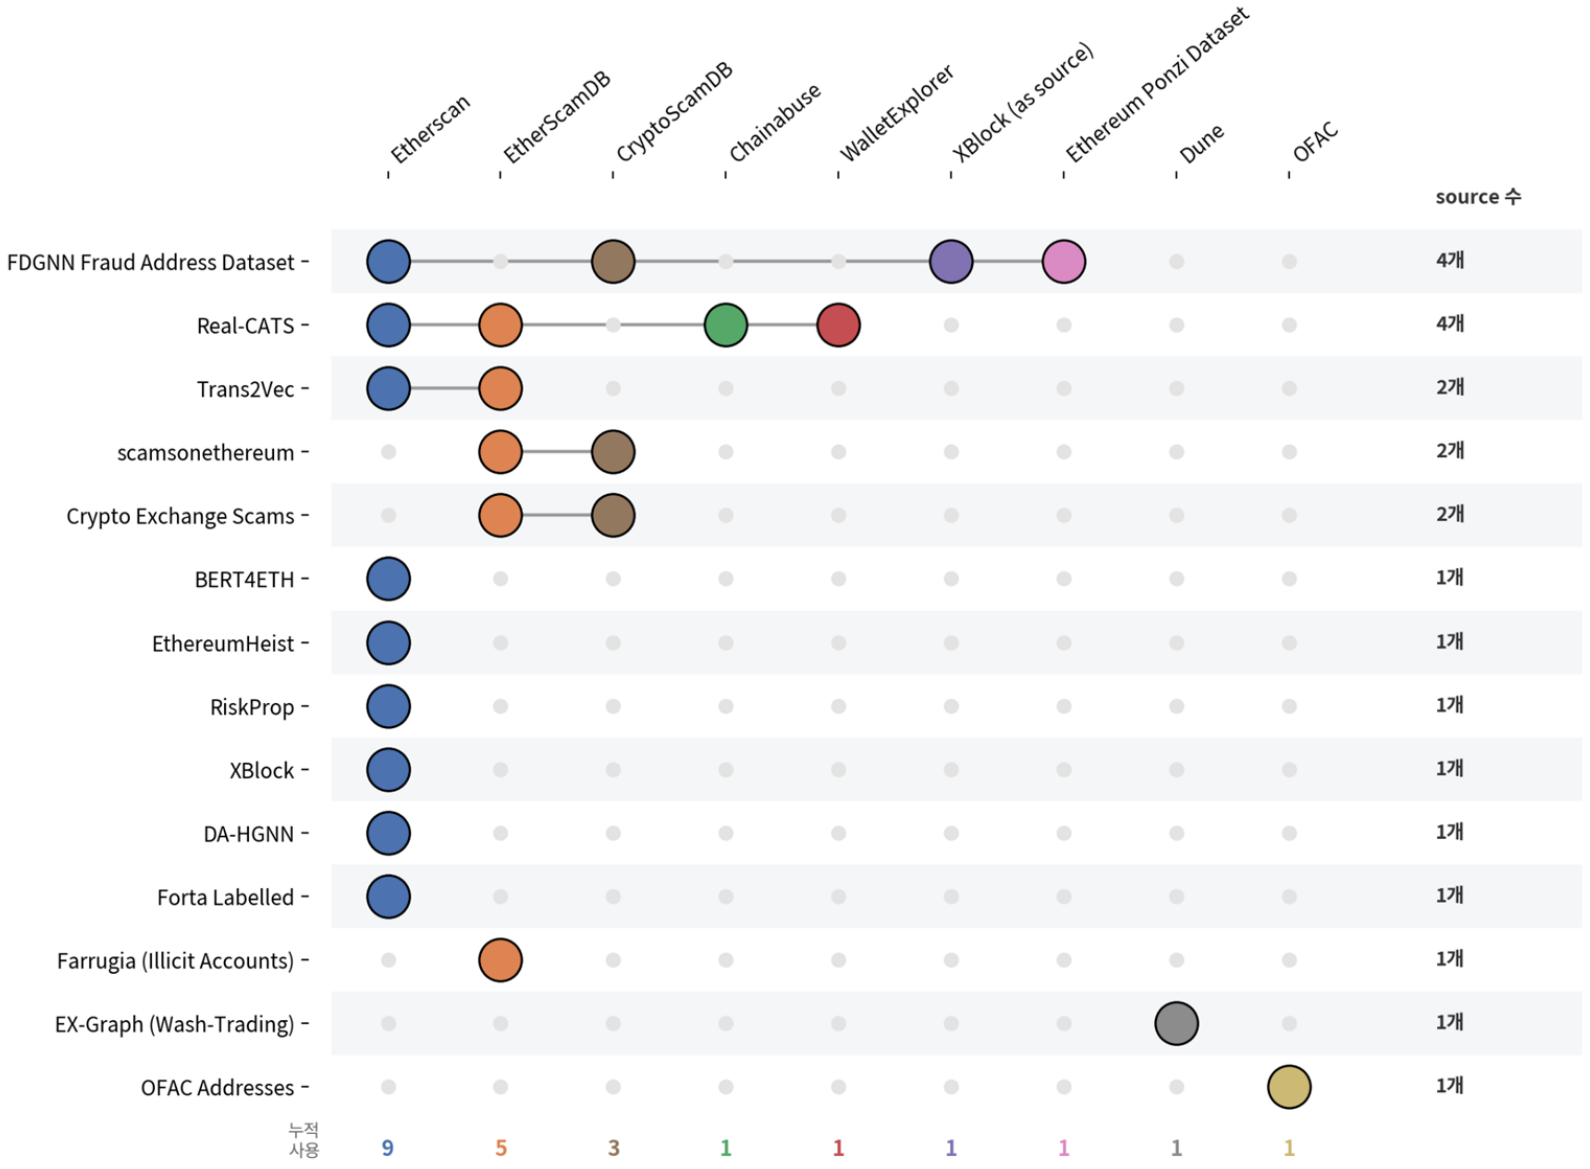
Source 관계도



Dataset Overview

PET

Source 관계도 - Dataset 기준



Dataset inventory

PET

Dataset	Paradigm	Root source	Addr.	Abn.	Norm.	Unlab.
Cryptocurrency Exchange Scams	Community	CryptoScamDB, EtherScamDB	110	110	0	0
EtherScamDB	Community	-	2,075	2,075	0	0
Farrugia	Community	EtherScamDB	2,349	1,996	0	353
Real-CATS	Community	Chainabuse, WalletExplorer, Etherscan, EtherScamDB	6,645	6,456	189	0
scamsonethereum	Community	8 blacklists + 6 prior datasets † (incl. EtherScamDB)	6,606	6,606	0	0
BERT4ETH	Research	Etherscan	22,249	5,431	0	16,818
DA-HGNN	Research	Etherscan	992	992	0	0
EthereumHeist	Research	Etherscan	109	108	0	1
FDGNN	Research	XBlock, Etherscan, CryptoScamDB	1,929	1,657	0	272
Forta	Research	Etherscan	6,532	6,532	0	0
RiskProp	Research	Etherscan	425	237	188	0
Trans2Vec	Research	Etherscan, EtherScamDB	1,207	1,207	0	0
XBlock	Research	Etherscan	19,564	1,124	0	18,440
EX-Graph	Unclassified	Dune	54	54	0	0
OFAC	Unclassified	U.S. OFAC Sanctions List	4	4	0	0

Dataset Overview

Root Source Description

- **Etherscan**
  - Ethereum explorer 기반의 공개 주소 태그 정보 제공.
  - Phishing, scam, hack 등 사용자 신고 및 검증된 malicious address 정보를 활용.
- **EtherScamDB**
  - Community-driven scam database.
  - 사용자 신고된 phishing/scam 사례를 수집하고 검토 과정을 거쳐 blacklist 형태로 관리.
- **Ethereum Ponzi Dataset**
  - Ponzi scheme 구조가 구현된 Ethereum smart contract 기반 dataset.
  - 신규 투자자의 자금으로 기존 투자자에게 수익을 지급하는 구조를 가진 contract를 이상 대상으로 정의.
- **Chainabuse**
  - Cryptocurrency abuse 신고 플랫폼 기반 source.
  - 사용자가 신고한 scam, fraud 등 blockchain 관련 악성 사례를 수집.

Dataset Overview

PET

Root Source Description

- **CryptoScamDB**
  - Cryptocurrency scam 정보를 수집하는 공개 database.
  - Scam 프로젝트 및 관련 blockchain address 정보를 제공.
- **Dune**
  - Blockchain analytics platform 기반 source.
  - On-chain transaction 데이터를 활용한 사용자 정의 분석 및 패턴 기반 탐지에 활용.
- **Wallet Explorer**
  - Cryptocurrency wallet clustering 서비스.
  - Address 간 연결 관계 및 wallet attribution 정보를 제공.
- **OFAC**
  - 미국 재무부 산하 해외자산통제국(Office of Foreign Assets Control)의 제재 목록 기반 source.
  - 제재 대상 개인·기관·서비스와 연관된 Ethereum address를 관리하며, malicious type이 아닌 regulatory status를 의미.

Dataset Overview

PET

Dataset	무엇을 악성으로 판단했는가
BERT4ETH	Etherscan에서 phishing account로 라벨된 Ethereum 주소
EtherScamDB	커뮤니티 신고와 검토를 거쳐 phishing·scam 등으로 blacklist에 등록된 대상과 관련 Ethereum 주소
Ethereum Illicit Accounts (Farrugia)	EtherScamDB에서 scam·phishing·Ponzi 등 불법 활동과 관련된 것으로 등록된 Ethereum 주소
EthereumHeist	Etherscan의 Heist-tagged 공격자 주소와, 해당 주소에서 도난 자금이 흘러간 경로를 추적해 확장한 자금세탁 의심 주소
FDGNN Fraud Address Dataset	기존 외부 출처에서 Phishing·Ponzi·Scam·Hack으로 분류된 Ethereum 주소
Forta Labelled Datasets	Etherscan에서 phish-hack·exploit·heist 등 위협 tag가 부여된 address / smart contract
OFAC Ethereum Addresses	미국 OFAC 제재 목록에 등재된 Ethereum 주소
Phishing Detection on Ethereum (Trans2Vec)	Etherscan과 EtherScamDB 양쪽에서 모두 phishing으로 보고된 Ethereum 주소

Dataset Overview

PET

Dataset	무엇을 악성으로 판단했는가
Real-CATS	Chainabuse에서 실제 피해자·사용자 신고를 통해 cybercrime 관련 주소로 보고된 Ethereum 주소
RiskProp	Etherscan에서 phishing 관련 account로 이미 라벨된 Ethereum 주소
XBlock Ethereum Phishing Transaction Network	Etherscan의 phish-hack tag가 부여된 Ethereum 주소
scamsonethereum	기존 blacklist·선행연구·Etherscan 등 여러 외부 출처에서 phishing·scam·exploit·heist·Ponzi 등 악성 활동과 관련된 것으로 분류된 주소
DA-HGNN Phishing Detection Dataset	Etherscan에서 phishing으로 라벨된 Ethereum 주소
EX-Graph – Wash-Trading	Dune에서 NFT wash-trading transaction에 참여한 것으로 식별된 Ethereum 주소
Cryptocurrency Exchange Scams – Ethereum subset	가짜 cryptocurrency exchange·trading website/app에 게시되어 피해 자금을 받는 데 사용된 Ethereum 주소

Dataset Overview

PET

Dataset	Source	수집 범위·시점	Data Size
BERT4ETH	Etherscan	2017.01 ~ 2022.05	7,057 phishing / 1M normal candidates
RiskProp	Etherscan	2019.12	243 phishing / 560 licit / 1.19M graph nodes
XBlock	Etherscan	수집 시점을 밝히지 않음	2.97M nodes / 13.55M edges / 1,165 phishing
DA-HGNN	Etherscan	2022.01 ~ 2024.04	66,402 addresses / 179,506 tx / 1,709 phishing
EthereumHeist	Etherscan	2018 ~ 2022	115 initial tags / 160K+ traced addresses
Forta Labelled	Etherscan	수집 시점을 밝히지 않음	7,570 phish-hack / 139 exploit / 71 heist
EtherScamDB	Community scam reports	수집 시점을 밝히지 않음	6,912 scam
Ethereum Illicit Accounts (Farrugia)	EtherScamDB	2019.04.17 snapshot (Block 3,800,000–3,805,000)	2,179 illicit / 2,502 normal

Dataset Overview

PET

Dataset	Source	수집 범위·시점	Data Size
Trans2Vec	Etherscan, EtherScamDB	??? ~ 2019.03.10	1,259 phishing / 1,259 sampled unlabeled
Real-CATS	Chainabuse, WalletExplorer, Etherscan, EtherScamDB	??? ~ 2024.05.30	12,561 criminal / 15,595 benign
scamsonethereum	기존 blacklist·선행연구 ·Etherscan	2017 ~ 2023	7,915 unique addresses
FDGNN Fraud Address Dataset	XBlock, Ethereum Ponzi Dataset, CryptoScamDB, Etherscan	수집 시점을 밝히지 않음	1,700 Normal / 1,660 Phishing / 200 Ponzi / 189 Scam / 826 Hack
EX-Graph – Wash-Trading	Dune	2022.03 ~ 2022.08	1,445 wash-trading addresses
OFAC Ethereum Addresses	U.S. OFAC Sanctions List	수집 시점을 밝히지 않음	96 unique ofac_sanctioned addresses
Cryptocurrency Exchange Scams – ETH subset	EtherScamDB, CryptoScamDB	수집 시점을 밝히지 않음	182 blockchain addresses

Methodology

동일 주소 기반 라벨 비교 프레임워크

03

Methodology

PET

데이터 전처리 및 라벨 표준화

*** 분석 대상:** Ethereum 네트워크 Address

- **주소 형식 통일**
  - Ethereum 주소 형식 통일
    - EX. 원본 Dataset A 0xAbC123...EF45, 원본 Dataset B 0xabc123...ef45 >> 비교용 키0xabc123...ef45
  - 한 데이터셋 내 동일 중복 주소 존재 검사

- **라벨 의미 표준화**
  - 표현은 다르지만 의미가 동일한 라벨을 공통 범주로 정리
    - EX1. fake_phishing, phishing, phish >> Phishing
    - EX2. hack, exploit, heist >> Hack / Exploit
  - 원본 라벨은 유지하고 **비교를 위한 표준 라벨을 별도로 생성해서 처리**함

Methodology

PET

데이터 전처리 및 라벨 표준화

*** 분석 대상:** Ethereum 네트워크 Address

- **라벨 속성 표준화**

  목적: 서로 다른 데이터셋의 라벨 비교 -> **라벨 간 공유하는 공통 관계 유형 정의**

  - **판정 성격 (어떤 판정을 받았는지?)**
    - **Abnormal** : 악성·이상 행위가 확인된 주소
    - **Normal** : 정상으로 명시적으로 검증된 주소
    - **Uncertain** : 정상·이상 여부가 명확하게 확정되지 않은 주소
  - **의미 축 및 표준 유형 (어떤 종류의 정보를 표현하는지?)**
    - **의미 축 & 축 내부의 세부 의미 표준화**

의미 축	의미	표준 유형 예시
Behavior	주소가 수행한 행위·공격 유형	Phishing, Scam, Hack/Exploit, Rug Pull, Wallet Drainer
Status	주소에 부여된 상태·분류 정보	Sanctioned, Illicit 등

Methodology

PET

데이터 전처리 및 라벨 표준화

*** 분석 대상:** Ethereum 네트워크 Address

- **라벨 속성 표준화**

  목적: 서로 다른 데이터셋의 라벨 비교 → **라벨 간 공유하는 공통 관계 유형 정의**

  - **라벨 구체성(제공하는 정보의 구체적인 정도는 어떠한가?)**
    - **Specific** : 구체적인 행위 유형이 명시됨
      → `Phishing`, `Scam`, `Hack/Exploit`
    - **Composite** : 둘 이상의 가능한 유형을 함께 포함
      → `Phishing | Hack/Exploit`
    - **Broad / Unspecified** : 이상 여부만 알 수 있고 구체적인 행위는 알 수 없음
      → `Unspecified Abnormal`

데이터셋	원본 라벨	판정 성격	의미 축	표준 유형	라벨 구체성
BERT4ETH	phisher_account	Abnormal	Behavior	Phishing	**Specific**
Ethereum Illicit Accounts (Farrugia et al.)	1	Abnormal	Behavior	Illicit/Criminal	**Unspecified**
EthereumHeist	AFKSystem	Abnormal	Behavior	Unspecified Abnormal	**Unspecified**
EthereumHeist	ATO Stolen Funds	Abnormal	Status	Stolen Funds	**Specific**

Methodology

데이터 전처리 및 라벨 표준화

PET

라벨 표준화에 따른 라벨 관계

- **표준 유형 고려**
  - 관계 자체에서는 라벨 구체성 고려 X

관계	의미	예시
Same Label	동일한 의미의 GT	Phishing ↔ Phishing
Compatible Label	표현은 다르지만 의미적으로 중첩·호환	phish-hack ↔ Phishing
Granularity Difference	포괄 라벨과 세부 라벨의 정보량 차이	Unspecified Abnormal ↔ Phishing
Uncertain / Coverage Difference	불확실하거나 한쪽의 정보가 부족	Uncertain ↔ Phishing
Axis Difference	서로 다른 의미축을 설명	Phishing(Behavior) ↔ Stolen Funds(Status)
Taxonomy Conflict	같은 축에서 구체 유형이 서로 다름	Phishing ↔ Hack/Exploit
Strong Conflict	정상·이상 판단이 직접 모순	Abnormal ↔ Normal

Methodology

PET

동일 주소 데이터셋 생성 및 Pair 구성

동일 주소 기준 데이터셋 생성 방법

- 각 데이터셋의 Ethereum 주소를 기준으로 **동일 주소 매칭**
- 동일 주소가 존재하는 데이터셋 조합별, **주소-라벨 정보를 하나의 비교 행으로 구성**
- 원본 라벨과 함께 **전처리한 표준 유형, 라벨 설명, Root Source 등으로 정리**

동일 Address	Dataset	표준 라벨
0x000...7865	BERT4ETH	Phishing
	Forta	Phishing
	Real-CATS	Phishing
	scamsonethereum	Scam

데이터셋 Pair 구성 방법

- 동일 주소가 존재하는 모든 데이터셋 조합을 **Dataset A–Dataset B Pair**로 생성
- 하나의 주소가 3개 이상의 데이터셋에 존재하면 가능한 모든 조합을 생성
  - 예: A, B, C에 존재 → A-B, A-C, B-C

Dataset A	Dataset B	표준 라벨 A	표준 라벨 B	비교 결과
BERT4ETH	Forta	Phishing	Phishing	일치
BERT4ETH	Real-CATS	Phishing	Phishing	일치
BERT4ETH	scamsonethereum	Phishing	Scam	불일치

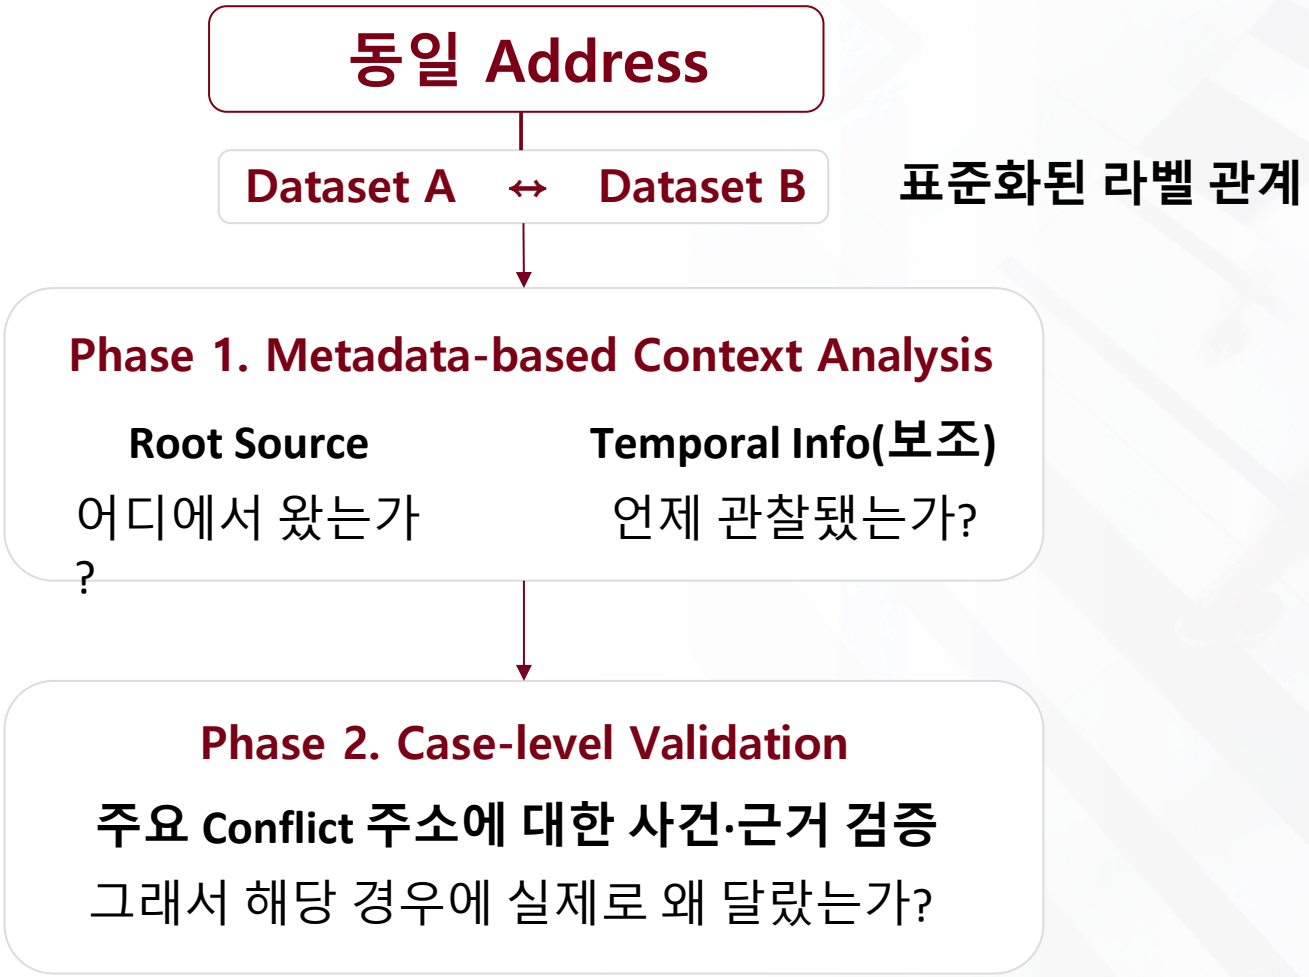
Methodology

PET

동일 주소 기반 라벨 비교 프레임워크 : 2 Phase 분석

*** 공통 분석 단위:** 동일 Ethereum Address

- **동일 주소 기반 라벨 차이 해석을 위한 2-Phase Analysis Framework**



Methodology

PET

동일 주소 기반 라벨 비교 프레임워크 : 2 Phase 분석

*** 공통 분석 단위:** 동일 Ethereum Address

■ Phase 1. Metadata-based Context Analysis



- **Root Source + Temporal Information**
  - 목적: 두 데이터셋의 라벨 판단은 서로 독립적인 정보에서 비롯된 것인가 ?
  - 4가지 관계 해석
    Same / Partially Shared / Different

    ex.
    Partially Shared: A = Etherscan + EtherScamDB, B = Etherscan
    Different : A = Etherscan, B = Chainabuse

Methodology

PET

동일 주소 기반 라벨 비교 프레임워크 : 2 Phase 분석

*** 공통 분석 단위:** 동일 Ethereum Address

■ Phase 1. Metadata-based Context Analysis

동일 Address

Dataset A ↔ Dataset B 표준화된 라벨 관계

- **Root Source + Temporal Information**
  - 판정 결과 해석(극단 값 예시)

	Label 일치·호환	Label 차이·충돌
같은 Root Source	① 동일 원천 정보가 반복·재사용된 것	② 동일 원천이 전처리·taxonomy 과정에서 달라짐
다른 Root Source	③ 독립 원천에서 동일·호환 판단한 것	④ 주요 판정 차이 후보

Methodology

PET

동일 주소 기반 라벨 비교 프레임워크 : 2 Phase 분석

*** 공통 분석 단위:** 동일 Ethereum Address

Phase 1. Metadata-based Context Analysis



표준화된 라벨 관계

- **Root Source + Temporal Information**
  - **Dataset의 수집 기간 또는 Snapshot/Cutoff 등 비교 가능한 시간 정보가 공개된 데이터셋을 선별**

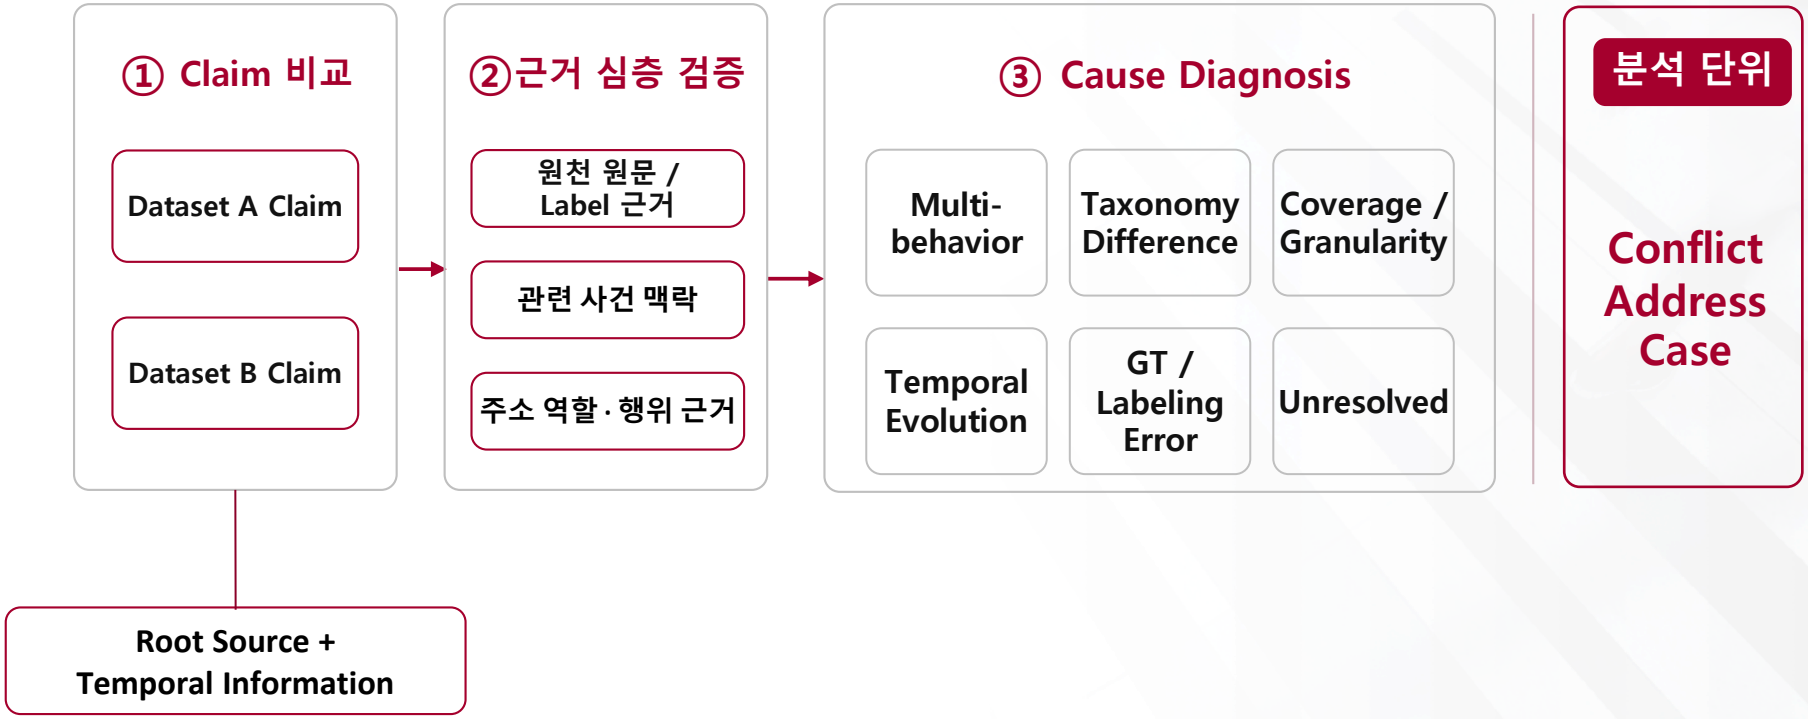
Dataset	확인된 Temporal Information
BERT4ETH	2017.01–2022.05
RiskProp	2019.12
DA-HGNN	2022.01–2024.04
Real-CATS	~2024.05.30
scamsonethereum	2017–2023

Methodology

PET

동일 주소 기반 라벨 비교 프레임워크 : 원천 출처 관계

- **Phase 2: Case-level Validation : 실제로 왜 달랐는가?**
  - 주요 라벨 차이에 대한 원인 검증
    - 검증 대상: 주요 충돌로 판단한 주소 하나
    - 검증 방법: 각 Case에서 Ground Truth의 원본 근거 & 추가 근거(관련 사건·행위) 직접 검토



Methodology

PET

동일 주소 기반 라벨 비교 프레임워크 — 데이터셋 레벨 방법론

- 지금까지의 방법론(Pair 비교)은 “데이터셋 A ↔ 데이터셋 B” 하나의 관계를 주로 본다

  → **이 절에서는 관점을 바꿔, “15개 데이터셋 전체를 놓고 볼 때 어떤 구조·패턴이 있는가”를 다루는 데이터셋 레벨 방법론을 정리한다**

Methodology

PET

동일 주소 기반 라벨 비교 프레임워크 — 데이터셋 레벨 방법론

1. **Overlap Ratio 산출**
   a. 각 데이터셋이 원 논문에서 공개한 malicious 라벨 규모를 확인
   b. 동일 데이터셋이 교집합 테이블 내에서 실제로 Abnormal로 확인된 주소 수를 집계
   c. 두 값의 비율(교집합 내 확인 수 ÷ 공개 규모)을 데이터셋별로 산출하여, “다른 데이터셋과 얼마나 같은 모집단을 공유하는가”를 나타내는 지표로 사용

1. **Taxonomy Coverage 분석**
   a. 15개 데이터셋 전체에서 등장하는 모든 세부유형(Phishing, Scam, Hack/Exploit, Rug Pull, Wash Trading 등)의 등장 빈도를 집계
   b. 특정 세부유형에 대해, 2개 이상의 데이터셋이 동일 주소에 동일 세부유형을 부여한(=교차검증 가능한) 사례가 몇 건인지 집계

Methodology

동일 주소 기반 라벨 비교 프레임워크 — 데이터셋 레벨 방법론

1. **Labeling Paradigm 분류**
   a. 각 데이터셋의 라벨 구축 절차(원 논문 방법론 섹션)를 검토하여 두 유형으로 분류
      i. Research-based: 그래프 임베딩·전파 알고리즘으로 시드 라벨을 확장하는 방식
      ii. Community-based: 피해자·커뮤니티의 자발적 신고를 집계하는 방식

1. **Temporal Analysis**
   a. 수집 시점이 공개된 데이터셋만 선별하고, 각 데이터셋의 수집 종료 시점을 대표 연도로 지정
   b. 각 주소에 대해 대표 연도가 가장 이른(earliest) 데이터셋의 라벨과 가장 늦은(latest) 데이터셋의 라벨을 추출하여 (earliest → latest) 순서쌍 구성
      i. 유지: earliest·latest 세부유형이 동일
      ii. 정제(refine): 포괄 라벨(Unspecified Abnormal 등) → 구체적 세부유형
      iii. 역행(reverse-generalize): 구체적 세부유형 → 포괄 라벨
      iv. 유형전환(type-shift): 서로 다른 구체적 세부유형 간 전환 (예: Phishing → Scam)

Results

04

Results

PET

전체 규모 및 데이터셋 중복 구조

- 전체 규모 및 중복 구조 : 교집합 테이블은 총 15개의 데이터셋을 사용하여 24,495개의 unique address로 구성되며, 각 address가 연결된 데이터셋 수의 분포는 다음과 같다.

데이터셋 포함 수	Address 수	비율
2	17,971	73.4%
3	563	2.3%
4	2,538	10.4%
5	823	3.4%
6	894	3.6%
7	738	3.0%
8	406	1.7%
9	449	1.8%
10	110	0.4%
11	3	0.01%

- 전체 address의 73.4%는 2개 데이터셋에만 걸쳐 있으며, 6개 이상 데이터셋에 동시에 등장하는 address는 10.5%(2,600개)에 불과하다.

Results

PET

- 각 데이터셋이 공개한 malicious(비정상) 라벨 규모 대비, 이 교집합 테이블에서 실제로 "Abnormal"로 확인된 수를 비교하면 아래와 같다

Dataset	공개 규모	교집합 내 확인	Overlap
RiskProp	243	237	97.5%
XBlock	1,165	1,124	96.5%
Trans2Vec	1,259	1,207	95.9%
EthereumHeist	115	108	93.9%
Farrugia	2,179	1,996	91.6%
Forta Labelled	7,780	6,532	84.0%
scamsonethereum	7,915	6,606	83.5%
BERT4ETH	7,057	5,431	76.9%
Crypto Exchange Scams	182	110	60.4%
DA-HGNN	1,709	992	58.0%
FDGNN	2,875	1,657	57.6%
Real-CATS	12,561	6,456	51.4%
EtherScamDB	6,912	2,075	30.0%
OFAC	96	4	4.2%
EX-Graph	1,445	54	3.7%

Results

PET

저 Overlap 데이터셋의 원인 — OFAC · EX-Graph

OFAC	96	4	4.2%
EX-Graph	1,445	54	3.7%

- **OFAC(4.2%) — “신원 기반” 라벨링: 온체인 행동이 아니라 “누가 지갑을 소유·통제하는가”라는 오프체인 정보로 등재**
  - 교집합 내 OFAC 주소 4건 중, 다른 데이터셋이 독립적으로 악성 확인해준 사례는 0건
  - Real-CATS 2건 → “Unspecified Abnormal”(근거 없는 포괄 라벨), XBlock 2건 → “Uncertain”(배경 노드로만 걸림)
  - 96%는 다른 데이터셋에 등장조차 하지 않음 → 크롤링·그래프 전파 방식으로는 애초에 포착 불가능한 라벨 유형
- **EX-Graph Wash-Trading(3.7%) — “행위 성격 자체”가 다름: Phishing/Scam/Hack은 “제3자 자산 탈취” 구조인 반면, Wash Trading은 “피해자 없는” 자기거래**
  - 교집합 내 EX-Graph 주소 54건 중 XBlock 44건은 전부 Uncertain(배경 노드)
  - 다른 데이터셋이 악성으로 확인해준 경우도 전부 “Phishing/Hack”일 뿐, “Wash Trading”은 단 한 건도 없음
    → 다른 15개 데이터셋의 taxonomy 자체에 “Wash Trading” 범주가 없어 발생하는 구조적 공백

Results

PET

Label 일치성 분류 결과 (24,495개 전수)

- **최종 분류 결과 (24,495개 전체, 정확히 7개 유형으로 분류)**
  - 불일치(충돌)로 볼 수 있는 것 (②+⑤+⑥) : 6,572개 (26.8%)
  - 충돌 아님 (①+③+④+⑦) : 17,923 (73.2%)

유형	개수	비율
① 악성 라벨 없음	17,694	72.24%
② 정상-악성 정면충돌	5	0.02%
③ 비교불가(악성판단 1개뿐)	79	0.32%
④ 비교불가(전부 포괄라벨)	54	0.22%
⑤ 세부유형 정면충돌	2,183	8.91%
⑥ 포괄-구체 불일치	4,384	17.90%
⑦ 완전 일치	96	0.39%

Results

PET

Uncertain-Dominated Overlap의 구조적 원인

- 교집합 24,495개 중 70.7%(17,330개)가 모든 데이터셋에서 Uncertain으로만 일치
- 이 70.7%를 데이터셋 조합별로 분해하면, 96.5%가 정확히 하나의 조합(BERT4ETH × XBlock) 에서 발생

관여 데이터셋 조합	Address 수	비율(그룹 내)
BERT4ETH × XBlock	16,732	96.5%
Farrugia × XBlock	332	1.9%
FDGNN × XBlock	248	1.4%
기타	18	0.1%

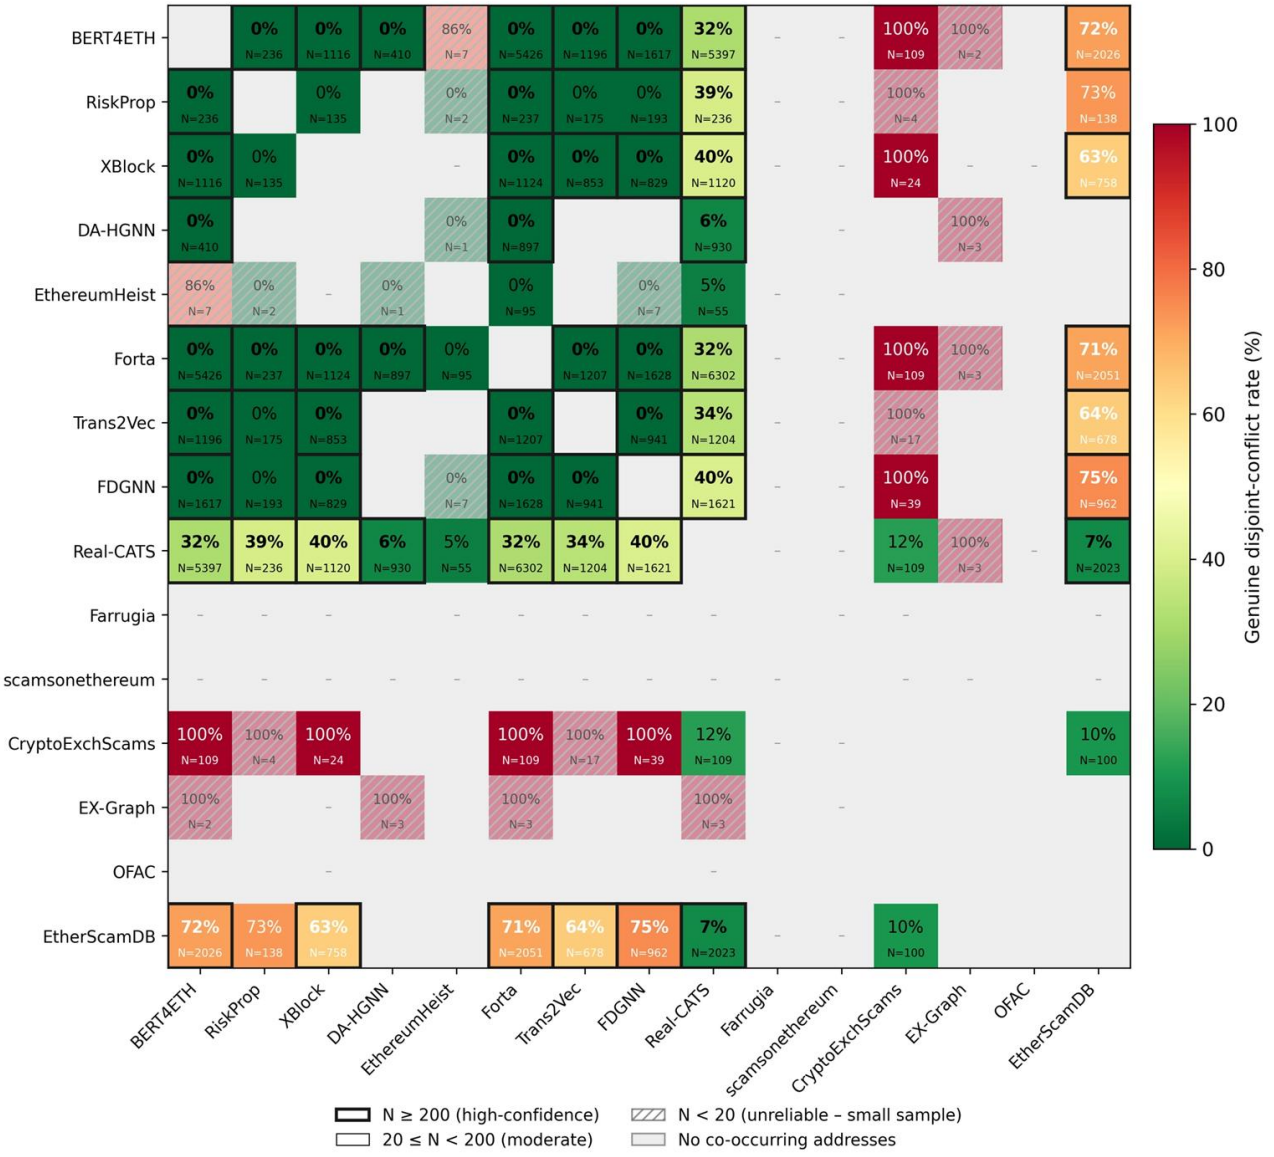
- BERT4ETH 원 논문: "1M normal candidates"는 negative sampling으로 무작위 추출한 학습용 후보군 — 개별 주소를 조사해서 정상이라고 판단한 게 아님
- XBlock 원 논문: 2.97M 노드는 Phishing 시드 주소에서 k-hop 그래프 탐색(BFS)으로 확장한 배경 그래프 노드 — 마찬가지로 개별 판단 근거 없음

-> 즉 두 데이터셋 모두 **"이 주소가 정상인지 조사했다"가 아니라 "학습에 쓸 후보를 모았다"는 사실이 각자의 구축 방법론에 명시되어 있음
-> 이 70.7%(17,330개)는 데이터셋들이 "같은 판단"을 내려서 겹친 게 아니라, 둘 다 "판단을 안 해서" 우연히 겹친 것

Results

PET

데이터셋 쌍(pair)별 세부유형 불일치율 히트맵



Results

PET

Temporal 기반 분석 — Label Transition Analysis (n=6,583)

Earliest → Latest	건수
Phishing → Phishing (유지)	2,986
Illicit/Criminal → Scam	1,221
Illicit/Criminal → Phishing	701
Unspecified Abnormal → Phishing	624
Phishing → Scam	482
Unspecified Abnormal → Scam	237
Illicit/Criminal → Unspecified Abnormal	73
Uncertain → Normal	51
Hack/Exploit → Hack/Exploit (유지)	46
Hack/Exploit → Unspecified Abnormal	36
Unspecified Abnormal → Hack/Exploit	34

- 초기의 포괄적/모호한 태그(Illicit/Criminal, Unspecified Abnormal)가 후기 데이터셋에서 더 구체적인 유형(Scam, Phishing)으로 "정제(refine)"되는 방향
- Phishing → Scam(482건)처럼 방향이 반대이거나, Hack/Exploit → Unspecified Abnormal(36건)처럼 오히려 구체성이 낮아지는 역방향 transition도 상당수 존재

Results

PET

Labeling Paradigm — Community-based vs Research-based

- **Community-based**
  - 출발점: 피해자가 신고 게시판에 "저 여기서 돈 잃었어요"라고 글을 씀
  - 판단 근거: 피해자의 진술, 즉 결과(피해 발생 여부)
    - 그래서 라벨이 붙는 방식: "이 주소로 돈을 보냈더니 사라졌다" → Scam / Phishing 등으로 분류
  - 특징: 기술적으로 그 주소가 정확히 어떤 수법을 썼는지는 몰라도, "누군가 피해를 봤다"는 사실만 있으면 라벨링이 가능함
  - 데이터 셋: Real-CATS, Farrugia, scamsonethereum, CryptoExchScams, EtherScamDB

- **Research-based**
  - 출발점: 온체인 트랜잭션 그래프를 분석
  - 판단 근거: 그 주소가 보인 행동 패턴(기법), 예를 들어 "짧은 시간에 자금을 여러 단계로 쪼개서 세탁했다", "가짜 컨트랙트를 배포해서 승인(approve)을 유도했다" 같은 온체인 흔적
    - 그래서 라벨이 붙는 방식: 그래프 구조나 트랜잭션 패턴이 알려진 공격 기법(phishing 시드 패턴 등)과 일치하는지로 분류
  - 특징: 피해자가 신고를 안 해도, 패턴만 맞으면 라벨링이 가능함
  - 데이터 셋: BERT4ETH, EthereumHeist, RiskProp, XBlock, DA-HGNN, Trans2Vec, Forta, FDGNN

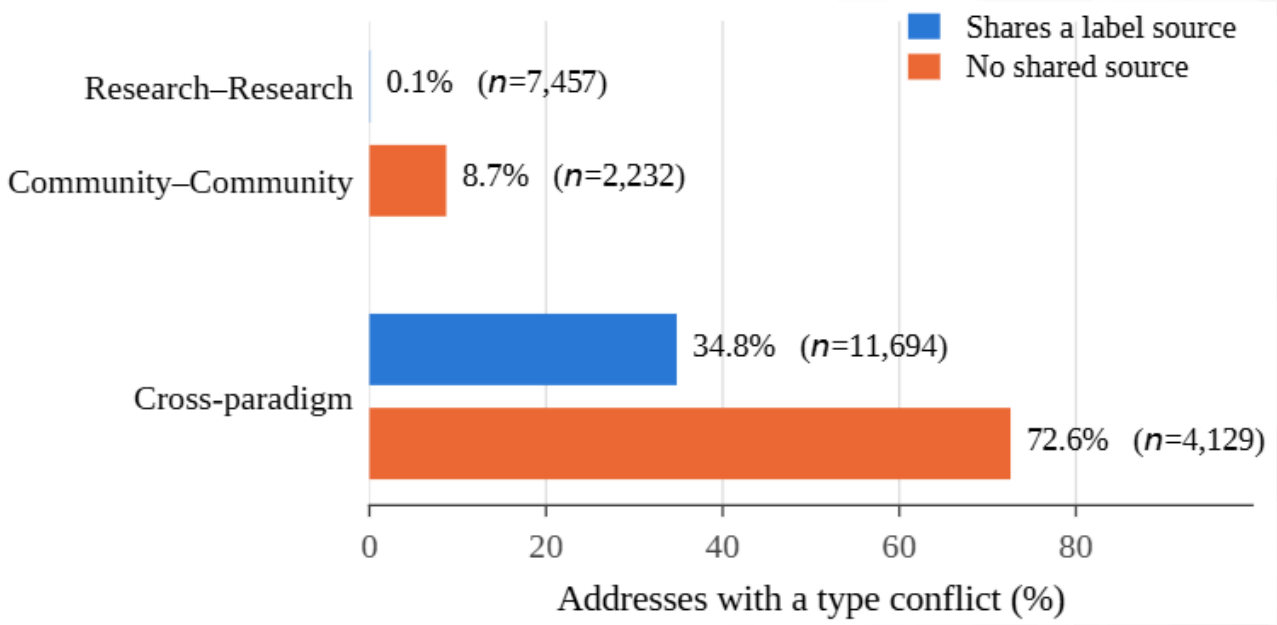
Results

PET

Root Source 기반 분석 : Source 공유 × 라벨링 패러다임

- **패러다임이 같으면 소스를 공유하지 않아도 8.7%, 패러다임이 갈리면 소스를 공유해도 34.8%**

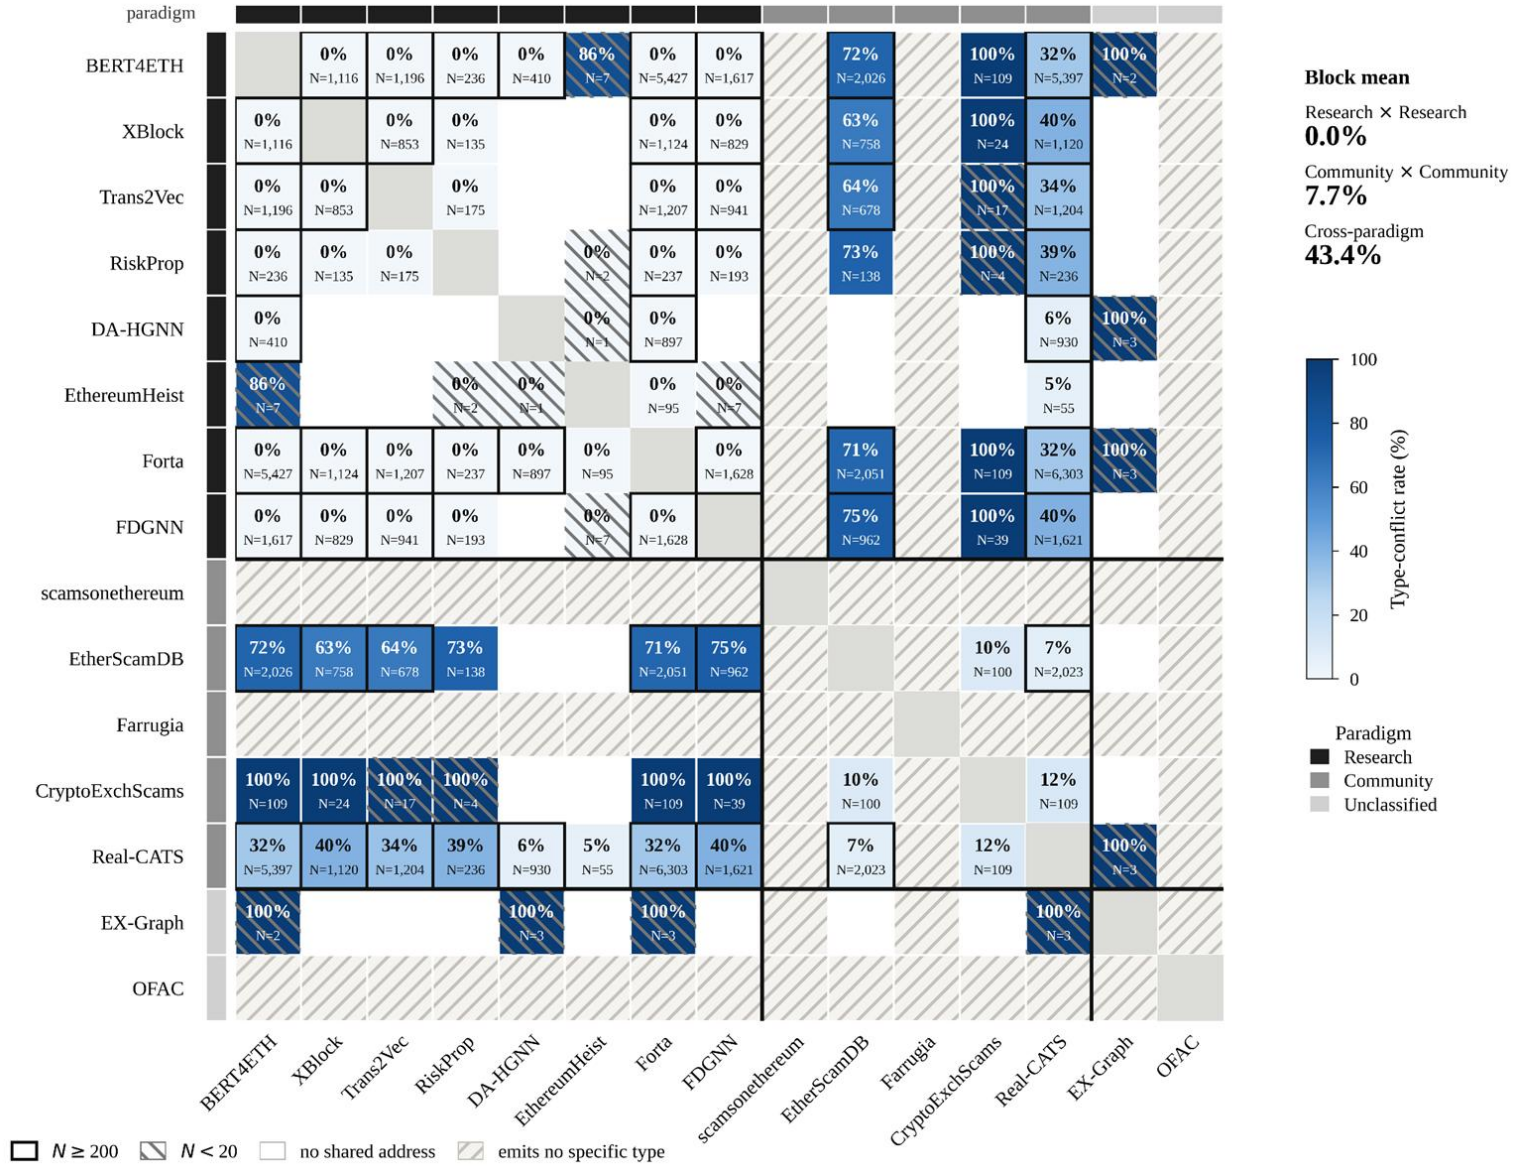
Source 공유	패러다임 관계	비교가능 주소	모순율
공유함	둘 다 Research	7,457	0.1%
공유 안 함	둘 다 Community	2,232	8.7%
공유함	서로 다른 패러다임	11,694	34.8%
공유 안 함	서로 다른 패러다임	4,129	72.6%



Results

PET

Root Source 기반 분석 : Source 공유 × 라벨링 패러다임



Results

PET

Root Source 기반 분석 : Source 공유 × 라벨링 패러다임

- **Research 라벨은 세부유형 정보를 담고 있지 않다**

Research 데이터셋	**라벨에 Phishing이 포함된 비율**
BERT4ETH / XBlock / Trans2Vec / DA-HGNN / RiskProp	100.0%
FDGNN	98.2%
Forta	97.4%
EthereumHeist	0.9%
전체	**98.2%**

- Research 데이터셋은 주소의 98.2%에 "Phishing"을 부여 — 사실상 상수 함수
  - EthereumHeist만 예외 — 사건 기준으로 라벨링하므로 Hack/Exploit 계열이 대부분
- 따라서 진영 간 불일치율은 Community 데이터셋의 내부 taxonomy 분포와 일치

Results

PET

Root Source 기반 분석 : Source 공유 × 라벨링 패러다임

- **불일치율은 Community의 taxonomy 분포와 일치한다**
- **Research 측이 상수이므로, 불일치 여부는 Community의 선택만으로 결정됨**

Community 데이터셋	비교 주소	실제 불일치율	"Phishing 아님" 비율
Real-CATS	6,401	31.2%	32.6%
EtherScamDB	2,056	71.4%	71.4%
CryptoExchScams	110	100.0%	100.0%

- "불일치율"은 두 진영이 얼마나 다르게 판단했는지를 재는 값이 아니라, Community 데이터셋이 Phishing 이외의 유형을 얼마나 쓰는지를 그대로 읽은 값이다

Results

PET

Root Source 기반 분석 : Source 공유 × 라벨링 패러다임

- **Research 8개의 데이터셋 전부가 Etherscan 을 사용.**
  - 그래서 Research x Research 모순율이 다른 것에 비해 작지 않았을까…

데이터셋	Root Source 출처	Etherscan 의존
BERT4ETH / XBlock	Etherscan phish-hack 태그	○
Trans2Vec	Etherscan ∩ EtherScamDB 양쪽 동시 신고	○
RiskProp	Etherscan 라벨 803개 (illicit 243 / licit 560)	○
DA-HGNN	Etherscan 피싱 라벨 2,761개	○
EthereumHeist	Etherscan Heist 태그 115개 (2022-04-27)	○
Forta (공개셋)	Luabase ethereum.tags — exploit/heist/phish-hack	○
FDGNN	XBlock 경유 + Etherscan 직접	○

Results

PET

Root Source 기반 분석 : Source 공유 × 라벨링 패러다임

- 불일치의 99%는 Scam vs Phishing

Community 측	Research 측	건수	비중
Scam	Phishing	6,990	99.0%
그 외	—	71	1.0%

- EtherScamDB는 Scamming을, Etherscan은 phish-hack을 기본값으로 쓴다. FDGNN 은 Hack/Exploit / Phishing / Ponzi 를 가지며, phishing 비율이 높다.
  - 같은 주소를 보고 한쪽은 " Scam", 다른 쪽은 "Phishing"이라 부른다.

Root Source 쌍	주소	충돌률
Etherscan × Etherscan	6,013	0.05%
Etherscan × FDGNN(혼합)	1,633	0.00%
Chainabuse × EtherScamDB	2,033	7.60%
Chainabuse × Etherscan	6,401	30.86%
Chainabuse × FDGNN(혼합)	1,621	40.41%
EtherScamDB × Etherscan	**2,065**	**71.05%**
EtherScamDB × FDGNN(혼합)	**962**	**76.12%**

Results

PET

- **각 데이터셋이 Abnormal 주소에 부여하는 세부유형**
  - **굵게 표시한 4종은 Phishing·Scam 유형을 사용하지 않는다.**
  - **유형 수가 하나인 곳은 그 유형 외에 다른 답을 낼 수 없다 → 충돌 여부가 전적으로 상대편의 선택으로 결정된다.** -> XBlock·Trans2Vec·DA-HGNN·BERT4ETH는 "피싱 탐지"라는 단일 과제를 위해 만들어졌으므로 이진 라벨이 정상이다. 문제는 이 데이터셋들이 후속 연구에서 범용 "이상 주소" 정답지로 재사용될 때 발생한다.

데이터셋	유형 수	주요 표준유형
BERT4ETH / DA-HGNN / Trans2Vec / XBlock	각 1종	Phishing
RiskProp	1종	Phishing | Hack/Exploit (복합)
CryptoExchScams	1종	Scam
EtherScamDB	2종	Scam / Phishing
FDGNN	3종	Hack/Exploit / Phishing / Ponzi
Real-CATS	8종	Scam / Hack/Exploit / Phishing …
EthereumHeist	8종	Hack/Exploit / Rug Pull / Unspecified …
Forta	16종	Phishing / Hack/Exploit / Unspecified …
Farrugia	**1종**	**Illicit/Criminal (포괄)**
scamsonethereum	**1종**	**Unspecified Abnormal (포괄)**
OFAC	**1종**	**Sanctioned**
EX-Graph	**1종**	**Wash Trading**

Results

PET

Phishing/Scam을 쓰는 11종 중 스스로 정의한 것은 2종뿐

그룹	라벨 생성 방식	데이터셋
위임형 (6종)	Etherscan/EtherScamDB 태그등 외부 태그를 그대로 복사 (원본 라벨이 isp=1, phisher_account, address-file membership 등 파일 소속 플래그)	Trans2Vec, BERT4ETH, XBlock, RiskProp, DA-HGNN, EthereumHeist
자체 세분류형 (2종)	신고자가 카테고리를 직접 선택, EtherScamDB는 category가 스키마상 Optional 자유	EtherScamDB, Real-CATS
통합/재병합형 (3종)	여러 출처를 합집합.	scamsonethereum, FDGNN, Forta

Etherscan — Phish / Hack 부여 기준이 공개되지 않는다. 신고에 요구되는 증거는 주소 + 스크린샷 URL 1개 + 자기진술이 전부다.

⇨ 논문의 주장을 바꿔보면,, 이렇게 하는건 어떤지,,

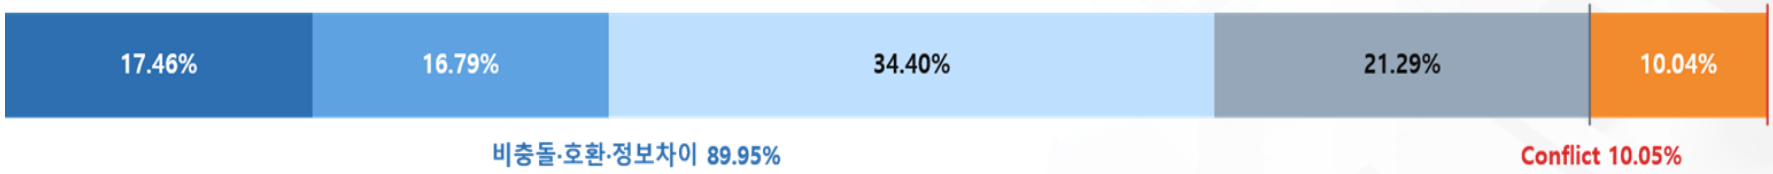
- **지금까지 하려던 주장**: "피싱과 스캠은 구분해야 하는데, 데이터셋들이 뒤섞어 썼다"
- **바꿀 주장**: "데이터셋들이 피싱과 스캠을 **따로 라벨링하면서, 정의는 아무도 안 했다**"

Results

PET

주소 충돌 주소 Pair에 대한 라벨 표준화 결과

- **라벨 관계 충돌 결과**
  - **라벨 관계에 따른 수치 및 해석**
    - **총 104,673 Pairs**



관계	Pair-Address	전체 중 비율	해석
Same Label	18,278	**17.46%**	동일한 의미의 Claim
Compatible Label	17,571	**16.79%**	표현은 다르지만 의미적으로 중첩·호환
Granularity Difference	36,008	**34.40%**	포괄 ↔ 구체 라벨의 정보량 차이
Uncertain / Coverage Difference	**22,289**	**21.29%**	불확실성 또는 한쪽만 명시적 판정
Axis-related Difference	**9**	**0.0086%**	서로 다른 의미축에 관한 정보
Taxonomy Conflict	**10,512**	**10.04%**	같은 Behavior 축에서 구체 유형이 다름
Strong Conflict	**6**	**0.0057%**	Abnormal ↔ Normal 직접 모순

Results

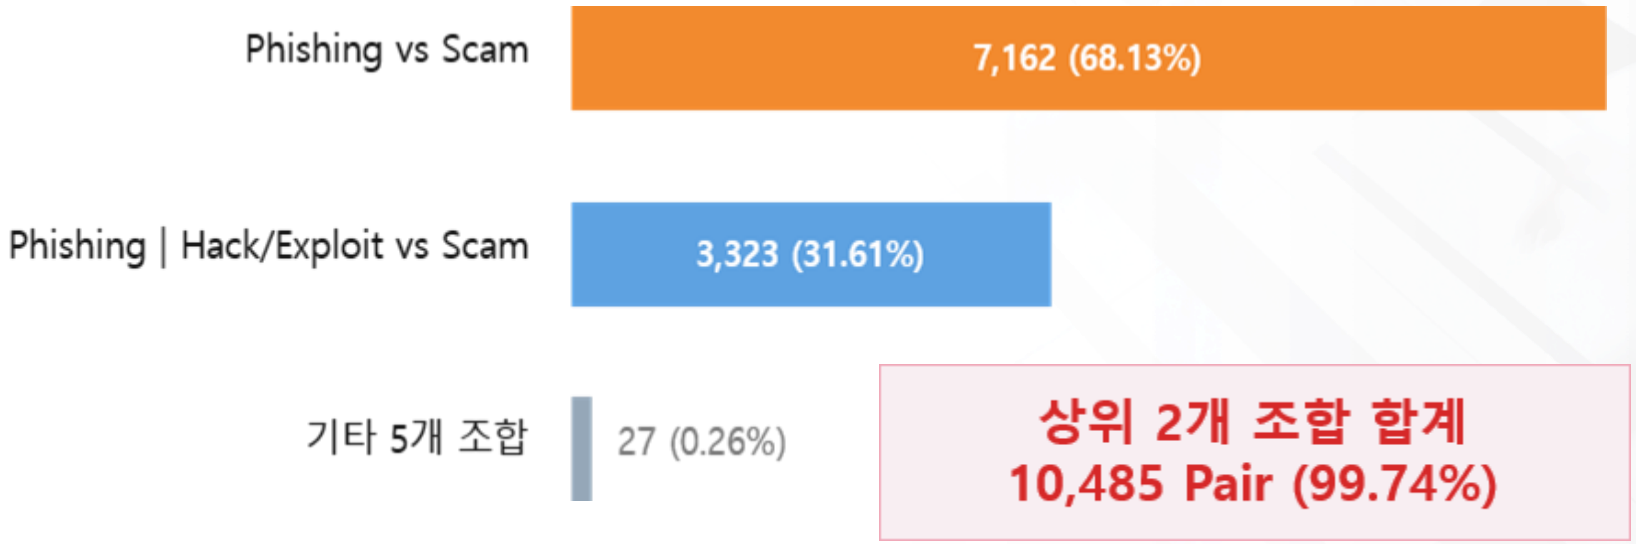
PET

주소 충돌 주소 Pair에 대한 라벨 표준화 결과

■ 라벨 관계 충돌 결과

- **Taxonomy Conflict 세부 내용(총 10,512 Pairs, 2,183 고유주소)**

조합별 Taxonomy Conflict



- **주요 충돌 Dataset Pair**

Phishing ↔ Scam

- BERT4ETH ↔ Real-CATS **1,698** / BERT4ETH ↔ EtherScamDB **1,458**

Phishing | Hack/Exploit ↔ Scam

- Forta ↔ Real-CATS **1,650** / EtherScamDB ↔ Forta **1,371**

Results

PET

주소 충돌 주소 Pair에 대한 라벨 표준화 결과

- **라벨 관계 충돌 결과 및 해석**
  - **대상 : Strong Conflict [Benign ↔ Wash Trading]**
  - **Pair : 총 6건 중 4건**
  - **고유 주소: 4개**

주소	Real-CATS	EX-Graph	기타
0x17331428...857fd	Normal || Benign	Abnormal || Wash Trading	XBlock: Uncertain
0x255f2007...65dbba	Normal || Benign	Abnormal || Wash Trading	—
0x718a085f...fb1013	Normal || Benign	Abnormal || Wash Trading	—
0xa3da2a30...60a31ad	Normal || Benign	Abnormal || Wash Trading	—

- **5건 중 4건이 동일한 패턴(Real-CATS ↔ EX-Graph)에서 발생함**

1. **데이터셋 탐지 범위 차이 가능성 (Real-CATS, EX-Graph)**
   a. Real-CATS: 피싱·스캠 등 “피해자가 있는” 사기 행위 중심
   b. Wash Trading: 혼자 사고파는 가짜 거래를 통한 거래량·가격 조작

=> 자신이 다루는 위협 유형 기준으로는 문제가 없었다! 일 수 있음

Results

PET

주소 충돌 주소 Pair에 대한 라벨 표준화 결과

- **라벨 관계 충돌 결과 및 해석**
  - **대상 : Strong Conflict**
    [Benign ↔ Illicit/Criminal, Benign ↔ Unspecified Abnormal]
  - **Pair : 총 6건 중 2건**
  - **고유 주소: 1개**

데이터셋	판정
RiskProp	Normal || Benign
Ethereum Illicit Accounts (Farrugia et al.)	Abnormal || Illicit/Criminal
scamsonethereum	Abnormal || Unspecified Abnormal
XBlock Ethereum Phishing Transaction Network	Uncertain || Uncertain

- **주소: `0x6a164122d5cf7c840d26e829b46dcc4ed6c0ae48`**

2. **정확히 어떤 근거로 악성 판정을 내렸는지 확인 어려움**

   이유: Ethereum Illicit Accounts, scamsonethereum 둘 다 포괄적 라벨 부여

Results

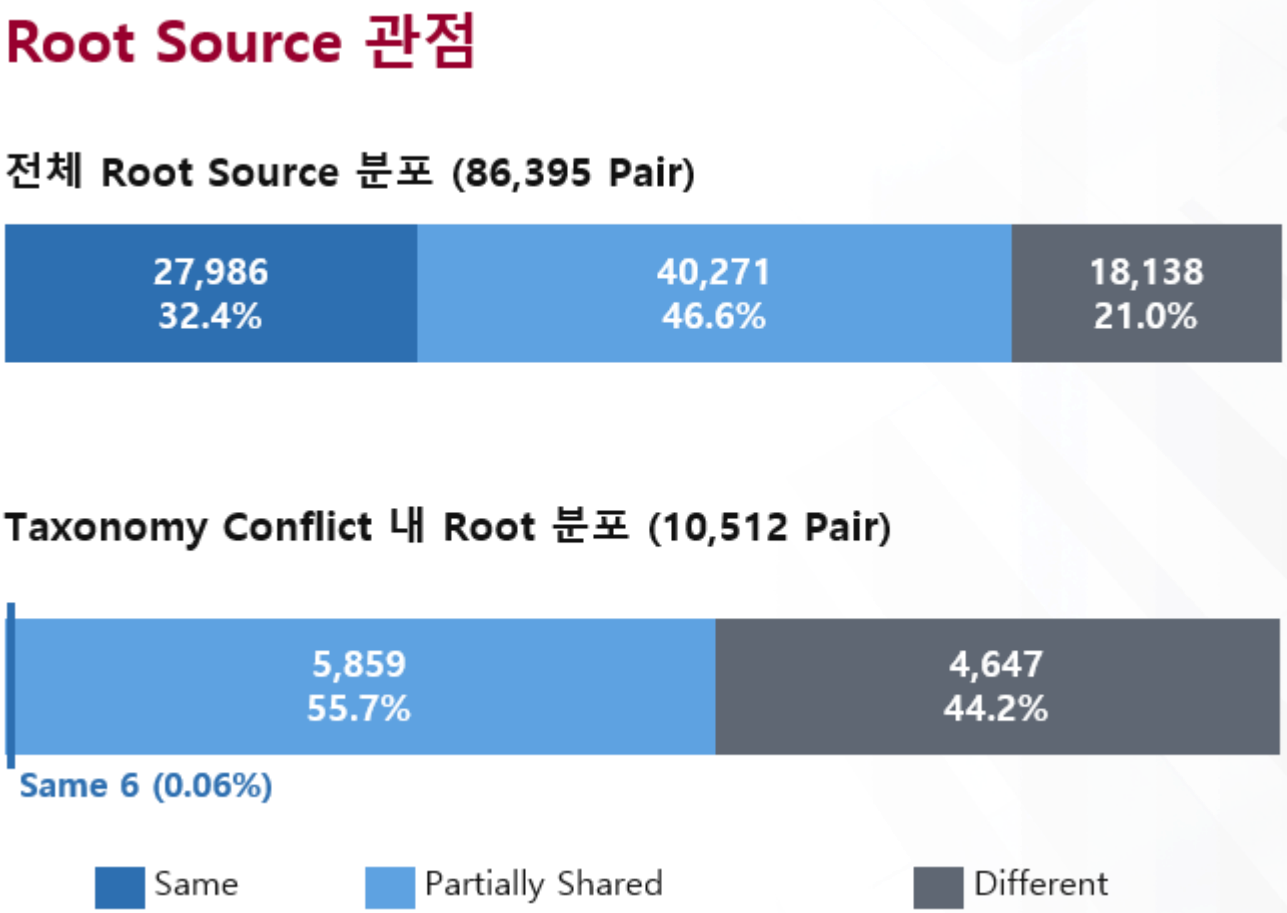
[종합] 주소 충돌 주소 Pair에 대한 라벨 표준화 결과

- **① 전체 라벨 차이의 대부분은 실제 충돌이 아니라 정보 구체성·Coverage·호환성 차이로 설명됨**
  - Same / Compatible Label / Granularity Difference 합치면 **68.65%**
- **② 엄격 기준에서 Taxonomy Conflict는 10.04%지만, 그중 99.74%가 Phishing–Scam 경계에 집중됨**
- **③ Normal ↔ Abnormal의 직접 모순은 6 Pair에 불과함**
  - **매우 희귀, 전체 중 0.0057%**

Results

주소 충돌 주소 Pair에 대한 2Phase 분석 결과

- **2 Phase 분석 결과**
  - **Phase 1에서의 주소 충돌 주소 Pair에 대한 Root Source 관계**

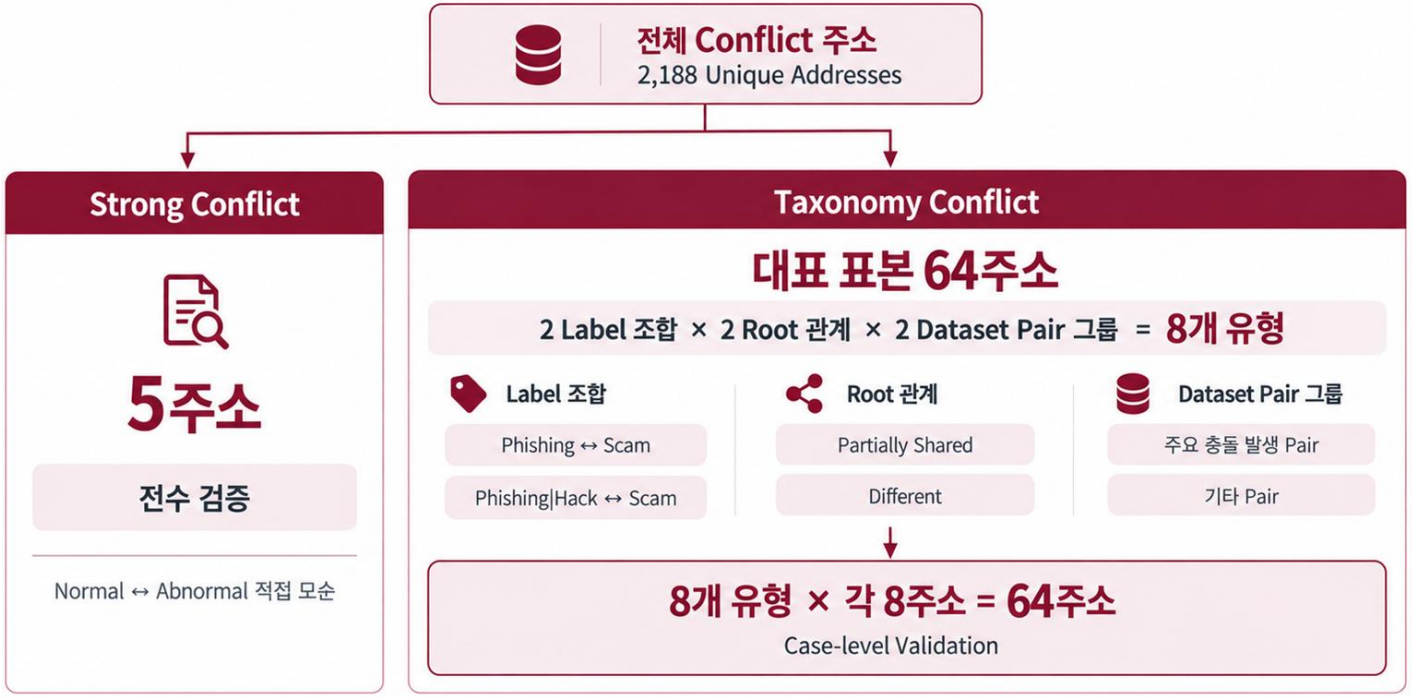


Results

PET

주소 충돌 주소 Pair에 대한 2Phase 분석 결과

- **2 Phase 분석 대상 선정**
  - **주요 Conflict: Taxonomy / Strong (전체 2,188 주소 중 대표 사례)**
  - **대표 사례 선정 : 2 Label 조합 × 2 Root 관계 × 2 Dataset Pair 그룹 = 8개 유형**
    - Label 조합: Phishing ↔ Scam / Phishing|Hack ↔ Scam
    - Root 관계: Partially Shared / Different
    - Dataset Pair: 주요 충돌 발생 Dataset Pair / 기타 Dataset Pair



Results

PET

주소 충돌 주소 Pair에 대한 2Phase 분석 결과

- **2 Phase 분석 결과**
  - **개별 검증 대상 : 64 주소**
  - **주요 결과 표**

원인 후보	의미
Multi-behavior	동일 주소가 실제 여러 악성 행위에 관여
Taxonomy Difference	같은 사건·행위를 데이터셋마다 다른 taxonomy로 표현
Coverage / Granularity Difference	데이터셋이 포착하거나 GT를 구성한 범위 자체가 다름
Temporal Evolution	서로 다른 시점의 주소 상태·행위를 반영
GT / Label Error	원천 또는 데이터셋 라벨 자체가 부정확
Processing Difference	동일/유사 Root라도 수집·매핑·전처리 과정에서 의미가 변형
Unresolved	공개 근거만으로 원인을 확정할 수 없음

Results

PET

주소 충돌 주소 Pair에 대한 2Phase 분석 결과

2 Phase 분석 결과 및 해석

- **Taxonomy Conflict 64건**

Taxonomy Conflict 원인	주소	64개 내 비율	현재 해석
Taxonomy Difference	50	78.1%	주로 Phishing ↔ Scam 표현 차이
Processing Difference	1	1.6%	Akropolis 사례
Unresolved	13	20.3%	주소 수준 외부 근거 부족

※ Multi-behavior, Coverage / GT Construction Difference, Temporal Evolution, GT / Label Error으로 최종 확정된 사례는 없음

- **Strong Conflict 5건**

Strong Conflict 원인	주소	5개 내 비율	현재 해석
GT / Label Error	2	40%	사건·거래 근거가 한쪽 Label의 부정확성을 지지
Coverage / GT Construction Difference	2	40%	서로 다른 GT 구축 범위·weak label에서 발생
Unresolved	1	20%	공개 근거만으로 우열 판정 불가

Results

PET

[종합] 주소 충돌 주소 Pair에 대한 2Phase 분석 결과

- **2 Phase 분석 결과 및 해석**

  ① Label 충돌 ≠ Ground Truth Error

  - **표면적으로 다른 Label이 실제 Ground Truth의 모순을 의미하지 않을 수 있음**

  ② 데이터셋마다 Label Space 동일 X

  - **Label이 서로 배타적인 class가 아닐 수 있음**

    => 두 Label이 <u>어떤 semantic dimension을 표현하는지 확인</u> 필요

  ③ Ground Truth 신뢰성은 Source만으로 결정되지 않음

  - **동일·유사 원천도 수집·매핑·Task 변환 과정(데이터셋 구축 과정)에서 의미가 달라질 수 있음**

Limitations

- 15개 데이터셋 중 명시적 Normal 라벨을 제공하는 것은 RiskProp·Real-CATS 2곳뿐

- anomaly detection 분야는 “악성 라벨 구축”에 자원이 집중되어 왔고, “정상 판정”은 대부분 부산물(무작위 배경 샘플, 미분류 후보군)로만 존재함
- 앞서 확인한 Uncertain-dominated overlap(70.7%) 역시 “정상”으로 통용되는 데이터의 상당수가 실제로는 “판단하지 않은 것”이지 “정상이라고 확인한 것”이 아님

- **함의:** 현재 이 분야의 anomaly detection 모델 다수가 사실상 검증되지 않은 negative sample로 학습·평가되고 있으며, 이는 실제 false positive rate 추정치를 낙관적으로 왜곡할 위험이 있음

Future work

- 본 연구에서 산출한 합의 라벨(consensus label) 및 신뢰도 점수를 ground truth로 사용하여, 실제 anomaly detection 모델을 학습·평가하는 실험을 계획 중

연구의 중요성

- 본 연구에서 산출한 합의 라벨(consensus label) 및 신뢰도 점수를 ground truth로 사용하여, 실제 anomaly detection 모델을 학습·평가하는 실험을 계획 중